


영화 추천 서비스 프로젝트 발표

22503110159 김광진





목차

01

서비스 설명

02

시연 영상

03

모델 설명

04

문제점 및 해결

05

성능 평가
및 혼동행렬



영화 추천 사이트

1. 텍스트 창에 원하는 영화를 설명
2. 해당 텍스트의 벡터를 추출하여 기존 리뷰 데이터와 유사도 비교
3. 기준을 바탕으로 걸러진 영화를 추천(영화와 키워드와 발췌 리뷰)
 - 부정 비율 **80%** 이상 영화 제외 (**GRU** 감성분류)
 - 리뷰 발췌를 긍정/부정/중립으로 라벨링하여 표시
 - 키워드를 빈도수 기반으로 추출 (**NLTK** 품사 태깅, 명사/형용사/동사만)
 - 해당 키워드가 긍정 리뷰에서 많이 나오면 초록, 부정이면 빨강
4. 원하는 키워드를 누르면 유사한 키워드를 가진 영화를 찾을 수 있음



사용자가 자연어로 입력한 문장의 의미를 분석하여 유사한 영화를 추천하는 사이트입니다. 한국어와 영어를 모두 지원하며

4천만 건 이상의 리뷰 데이터를 기반으로 추천을 제공합니다.



시연 영상

시스템 모델

[검색] BGE-M3 트랜스포머

- 입력: 리뷰 텍스트 (최대 512 토큰)
 - 출력: 256차원 밀집 벡터
- 특징: 100개+ 언어 지원, FP16 GPU 가속
- 유사도: 코사인 유사도 (L2 정규화 후 내적)
- 인덱스: FAISS IVF-PQ (8,192 클러스터, 16 서브퀀타이저)
 - Pooler 활성화: Tanh
- 규모: 40,217,722 리뷰 벡터, 26,761편 영화

[키워드 추출] NLTK 품사 태깅

- 토큰화: 공백 기반 (영어 99.5%)
- 품사 필터: 명사(NN), 형용사(JJ), 동사(VB)만 추출
 - 빈도수 기반 상위 8개 키워드
- 감성 색상: 긍정 리뷰에서 많이 등장 = 초록, 부정 = 빨강

[분류] GRU 감성분류

- Embedding(40,001, 32) → GRU(32) → Dense(16, tanh) → Dense(2, softmax)
 - MAX_LEN: 100
 - VOCAB_SIZE: 40,000
 - Optimizer: RMSprop (lr=0.001)
 - EarlyStopping: patience=3, val_loss 기준
- 학습 데이터: 개별 리뷰 평점 7~8(긍정) vs 3~4(부정), 각 50만 건
 - 내부 정확도: 83.0%



데이터 수집 및 전처리

수집 방법

- Letterboxd 영화 리뷰 수집
- IMDB 영화 리뷰 수집
- 두 사이트의 데이터를 하나로 통합

해결한 문제

문제	해결 방법
화면을 내려야 리뷰가 보임	자동으로 스크롤하여 수집
같은 영화인데 이름이 다름	영화 제목을 통일
의미 없는 짧은 리뷰 존재	너무 짧은 리뷰 제거

결과

- 약 4,000만 건 리뷰 확보
- 영화별 리뷰 데이터 구축

감성분석 모델 구축

목표

리뷰가 긍정인지 부정인지 자동 판단

모델 구조

리뷰 입력

↓

단어 벡터 변환 (Embedding)

↓

문맥 분석 (GRU)

↓

긍정 / 부정 분류 (Softmax)

해결한 문제

문제	해결 방법
리뷰에 정답 데이터가 없음	평점을 이용해 자동 라벨 생성 (Weak Supervision)
모델이 자신의 예측 결과만 학습	평점 데이터를 직접 사용 (Self-Training 제거)
짧은 리뷰에서 성능 부족	모델 크기 확장 (GRU 32 → 64)

결과

- 감성 자동 분류 가능
- 추천 점수 계산에 활용

영화 검색 서비스 구축

목표

사용자가 입력한 영화와 비슷한 영화를 빠르게 찾기

해결한 문제

문제

4천만 건 데이터를 모두 비교하면 너무 느림

데이터가 너무 많아 메모리 부족 발생

한국어로 검색해도 영어 리뷰를 찾고 싶음

해결 방법

검색용 색인을 생성하여 비교 범위 축소 (FAISS IVF-PQ)

데이터를 나누어 저장하며 처리 (Streaming)

다국어 언어모델 사용 (BGE-M3)

결과

- 대규모 데이터에서도 빠른 검색 가능
- 한국어 검색 지원

GRU 모델 성능 평가

GRU 감성분석 모델 성능 평가

테스트셋	정확도	긍정 탐지율	부정 탐지율	특징
IMDB 단문 리뷰 (5,946건)	55.8%	77.8%	2.4%	긍정 편향 발생
IMDB 전체 리뷰 (50,000건)	73.5%	56.9%	78.8%	가장 안정적인 성능
극단 평점 리뷰 (10,000건)	-	90.4%	1.1%	긍정 리뷰 탐지 우수

극단 평점 리뷰 분류 결과

실제 평점	긍정	중립	부정
9~10점	90.4%	9.5%	0.0%
1~2점	92.4%	6.5%	1.1%

IMDB 데이터 셋 및 명작의 긍정 리뷰,
망작의 부정 리뷰 셋으로 검증

GRU 모델 성능 평가

GRU 감성분석 모델 성능 평가				
테스트셋	정확도	긍정 탐지율	부정 탐지율	특징
IMDB 단문 리뷰 (5,946건)	55.8%	77.8%	2.4%	긍정 편향 발생
IMDB 전체 리뷰 (50,000건)	73.5%	56.9%	78.8%	가장 안정적인 성능
극단 평점 리뷰 (10,000건)	-	90.4%	1.1%	긍정 리뷰 탐지 우수

IMDB 데이터 셋으로 검증

추천 서비스 혼동행렬

	실제 관련 있음	실제 관련 없음
추천됨	414 (TP)	86 (FP)
추천 안됨	56 (FN)	-

성능 지표

지표	계산식	결과
Precision (정밀도)	$TP / (TP + FP)$	82.8%
Recall (재현율)	$TP / (TP + FN)$	44.0%

결과 해석

- 추천된 영화의 82.8%가 실제 관련 영화
- 오추천(False Positive)은 17.2%
- 추천 영화 5개 기준 약 4개가 적절한 추천
- 쉬운 검색어 Recall: 93.3%
- 어려운 검색어 Recall: 22.9%

평가 기준 선정 이유

Precision을 핵심 지표로 사용

- 사용자는 추천된 영화를 직접 확인함
- 관련 없는 영화가 추천되면 서비스 신뢰도 하락
- 누락된 영화(Recall)보다 오추천(FP)이 사용자 경험에 더 큰 영향

→ 추천 품질 관점에서 Precision 82.8%를 주요 성과로 평가

추천 점수 및 동작 로직

$\log(1 + \text{유사 리뷰 수})$:

점수 = $\log(1 + \text{유사 리뷰 수}) \times \text{평균 평점}$

- 유사 리뷰가 많을수록 점수 올라감
- 로그를 씌워서 인기 영화 독점 방지
- 예: 1000건 vs 100건 → 6.9 vs 4.6 (15배 차이를 1.5배로 압축)
- log 없으면 리뷰 많은 영화가 무조건 1위

검색 흐름:

1. 사용자 입력 → BGE-M3로 벡터화
2. Stage 1: 영화 평균 벡터에서 상위 300개 후보
3. Stage 2: 전체 리뷰에서 유사 리뷰 5,000개 검색
4. 후보 300개에 속하는 유사 리뷰만 영화별 집계
5. 영화별 점수 = $\log(1 + \text{유사리뷰수}) \times \text{평균평점}$
6. 부정 비율 80% 이상 영화 제외
7. 점수순 정렬 → 상위 5개 추천

× 평균 평점:

- 유사 리뷰의 평점 평균 (리뷰어가 해당 영화에 준 점수)
- 관련성(리뷰 수)만이 아니라 품질(평점)도 반영
- 유사 리뷰 10건인데 평점 9.0 → 점수 21.6
- 유사 리뷰 10건인데 평점 5.0 → 점수 12.0

예시:

Miracle in Cell No. 7: $\log(1+28) \times 9.29 = 3.37 \times 9.29 = 31.3$

Hachi: $\log(1+26) \times 9.19 = 3.30 \times 9.19 = 30.3$